

Uniwersytet Warszawski
Wydział Fizyki

Andrzej Oreszczuk
Nr albumu: 393976

Zastosowanie
metod uczenia
maszynowego do
zadania Bounding
Box Regression
związanego z
wykrywaniem
obiektów na
rzeczywistych
zbiorach danych
plików graficznych

Praca licencjacka
na kierunku studiów zastosowania fizyki w biologii i medycynie

Praca wykonana pod kierunkiem
doktora Szymona Nowakowskiego
Wydział Matematyki, Informatyki i Mechaniki

Warszawa, 12.2024r.

Streszczenie

Celem pracy było stworzenie metody wykorzystującej głęboką sieć neuronową wykonującą zadanie Bounding Box Regression przewidującej ramki ograniczające obiekty na obrazach z wykorzystaniem przybliżonej, nieprecyzyjnie oznaczonej ramki ograniczającej dany obiekt. Generowanie precyzyjnych ramek ograniczających jest ważnym zadaniem w wielu zastosowaniach, a także może zredukować wymaganą ilość pracy ludzkiej przy tworzeniu danych treningowych dla innych sieci. W ramach pracy powstało takie narzędzie i zostało przetestowane na rzeczywistym zbiorze obrazów mikroskopowych przedstawiających grana. Uzyskano na tym zbiorze większą precyzję przewidywań w porównaniu z najnowszym modelem YOLO; szeroko stosowanym zaawansowanym systemem detekcji obiektów. Zbadano również jego zastosowanie do innych zadań związanych ze zbiorem, oraz rozważono eksperymenty związane z zastosowaniami sieci zarówno przy analizie danych biologicznych, jak i innych danych. W pracy porównano też jakość działania kilku wersji modelu, w celu zbadania wpływu wielkości pola recepcyjnego neuronów wyjściowych części konwolucyjnej sieci na jakość przewidywań, i zaobserwowano, że zwiększenie pola recepcyjnego poprawia jakość działania modelu.

Słowa kluczowe

Bounding Box Regression, głębokie sieci neuronowe, detekcja obrazu, chloroplast, granum, tylakoid

Tytuł pracy w języku angielskim

Machine Learning Methods in Bounding Box Regression Task in Relation with Object Detection in Images from Real Data Sets

Spis treści

1	Wstęp	2
2	Przegląd literatury	3
3	Metodyka	7
3.1	Model	7
3.1.1	Część konwolucyjna	7
3.1.2	Moduł uwagi	8
3.1.3	Część liniowa	8
3.2	Trening	9
3.2.1	Przygotowanie danych	9
3.2.2	Parametry treningu	10
3.3	Zbiory danych	10
3.3.1	Dane syntetyczne	11
3.3.2	Manuskrypty	11
3.3.3	Grana	12
4	Wyniki	13
4.1	Metryki i funkcja straty	13
4.2	Manuskrypty	14
4.2.1	Transfer wag	16
4.2.2	Benchmarking	17
4.3	Grana	19
4.3.1	Benchmarking	20
4.3.2	Kąt obrotu	22
5	Wnioski	23
6	Podziękowania	24

Spis rysunków

1	Schemat architektury sieci LeNet1	5
2	Porównanie architektury sieci LeNet-5 i AlexNet	6
3	Schemat architektury stworzonej sieci BBR	8
4	Przykładowe obrazy ze zbioru syntetycznego	11
5	Przykładowe obrazy ze zbioru manuskryptów	12
6	Przykładowe obrazy ze zbioru zdjęć gran	12
7	Przebieg treningu na zbiorze manuskryptów	15
8	Przebieg treningu na zbiorze manuskryptów z transferem wag . .	17
9	Przykłady przewidzianych ramek ograniczających na zbiorze manuskryptów	18
10	Przebieg treningu na zbiorze zdjęć gran z transferem wag	20
11	Przykłady przewidzianych ramek ograniczających na zbiorze zdjęć gran	21
12	Przykłady ramek ograniczających błędnie przewidzianych przez sieć YOLO	22
13	Przykładowe grana obrócone przy użyciu sieci do poziomych lub pionowych pozycji	23

Spis tabel

1	Wyniki treningu na zbiorze manuskryptów	15
2	Wyniki treningu na zbiorze manuskryptów z transferem wag . . .	16
3	Porównanie metryk przewidywań sieci na zbiorze manuskryptów	18
4	Wyniki treningu z transferem wag na zbiorze zdjęć gran	19
5	Porównanie metryk przewidywań sieci na zbiorze zdjęć gran . . .	21

1 Wstęp

Bounding Box Regression (BBR) to zadanie związane z wykrywaniem obiektów należące do dziedziny uczenia maszynowego. Detekcja obiektów (ang. *object detection*) polega na wykrywaniu w plikach graficznych obiektów różnych klas (na przykład samochodów, ludzkich twarzy, organelli komórkowych) i określaniu ich lokalizacji. Jest stosowane w wielu dziedzinach, takich jak medycyna i agrykultura [23, 6].

Bounding Box Regression to jedna z najczęściej używanych metod służących do określania ramek ograniczających wykrytych obiektów w object detection. Dla niektórych zastosowań tego zadania precyzja ustalenia granic obiektów jest szczególnie ważna, jak w przypadku metod ustalających wysokości budynków na zdjęciach satelitarnych na podstawie wykrytych rozmiarów ich ramek ograniczających [24]. Jednocześnie jednym z największych ograniczeń wykrywania obiektów jest konieczność ręcznego tworzenia obszernych i precyzyjnych zbiorów danych treningowych.

Celem tej pracy było stworzenie modelu Bounding Box Regression przewidującego ramki ograniczające obiektów na podstawie obrazu oraz podanej przez człowieka przybliżonej ramki ograniczającej. Taka metoda mogłaby zwiększyć precyzję wykrywania obiektów dzięki podanej dodatkowej informacji o położeniu położeniu obiektu oraz zmniejszyć wymaganą ilość pracy człowieka przy tworzeniu danych treningowych, który mógłby oznaczyć ramkę ograniczającą obiekt z mniejszą precyzją.

Motywacją do powstania pracy były projekty promotora dotyczące zadań detekcji obrazu. Praca [25] wymagała dużego nakładu pracy człowieka, który musiał stworzyć zbiór danych przez precyzyjne oznaczanie ramek ograniczających wystąpienia słowa "Lacandon" na skanach hiszpańskojęzycznych rękopisów, ponieważ narzędzia detekcji obiektów wymagają zbiorów treningowych z precyzyjnie oznaczonymi granicami obiektów. Narzędzie wykonujące zadanie Bounding Box Regression mogłoby ułatwić tą pracę przez udoskonalanie nieprecyzyjnych (a więc wykonanych w dużo mniejszym czasie) ludzkich oznaczeń, co zmniejszyłoby wymagany nakład pracy człowieka.

W pracy [5] dotyczącej badania zdjęć wykonanych przy użyciu mikroskopii elektronowej przedstawiających grana, czyli struktury występujące w chloroplastach, jednym z problemów było znajdowanie kąta obrotu danego grana na zdjęciu. W niniejszej pracy pokażę jak do tego zadania można wykorzystać sieć wykonującą Bounding Box Regression przez minimalizację pola przewidzianej ramki ograniczającej.

2 Przegląd literatury

Stosowanie uczenia maszynowego do zadań związanych z analizą obrazów ma długą historię. Jednym z pierwszych przykładów jest Perceptron, model sieci neuronowej skonstruowany po raz pierwszy w 1957 roku przez Franka Rosenblatta [21, 20]. Perceptron był propozycją modelu reprezentującego procesy zachodzące w ludzkim mózgu w trakcie rozpoznawania obiektów i składał się z trzech komponentów: sensorycznego, asocjacyjnego i systemu odpowiedzi.

System sensoryczny składał się z fotokomórek odpowiadających punktom na siatkówce i otrzymywał binarne dane wejściowe reprezentujące oświetlenie. Każda z fotokomórek łączyła się z wieloma jednostkami systemu asocjacyjnego, w czasie pobudzenia przekazując do nich sygnał zgodnie z indywidualnymi wagami danego połączenia.

System asocjacyjny składał się z jednostek o parametrach Q i V , otrzymujących hamujące lub pobudzające impulsy z wielu komórek systemu sensorycznego. Jeśli suma otrzymanych impulsów danej jednostki przekraczała próg Q , przekazywała ona do jednej lub wielu jednostek systemu odpowiedzi impuls o wartości V . Jednocześnie każde pobudzenie danej jednostki zwiększało jej parametr V , umożliwiając adaptację sieci.

System odpowiedzi składał się z niewielkiej liczby wykluczających się jednostek odpowiadających wynikowi klasyfikacji wejściowego sygnału. Każda jednostka otrzymywała wejścia z systemu asocjacyjnego i była aktywowana kiedy

(w zależności od trybu) suma lub średnia impulsów wejściowych przekraczała próg Q_r . Jednostki systemu odpowiedzi miały też wyjściowe hamujące połączenia ze sobą i systemem asocjacyjnym, co gwarantowało wystąpienie tylko jednej najsilniej pobudzonej odpowiedzi.

Perceptron mógł być uczony klasyfikacji przez wprowadzenie danych i wymuszanie poprawnej odpowiedzi co powoduje zwiększenie wartości V tych jednostek systemu asocjacyjnego które pobudzały wymuszoną odpowiedź. Wartości V pozostałych aktywowanych przez dane jednostek pozostają takie same ponieważ ich aktywacja jest blokowana przez połączenia zwrotne z systemu odpowiedzi.

Mimo istnienia perceptronu, wczesnej wersji sieci neuronowej zdolnej do adaptacji i uczenia się, w kolejnych dekadach do zadań związanych z analizą obrazu takich jak automatyczne odczytywanie drukowanego pisma nie stosowano szeroko uczenia maszynowego. Wynikało to głównie z ograniczonej mocy obliczeniowej komputerów. Do późnych lat osiemdziesiątych w tej dziedzinie dominowały metody dopasowujące dane do znanych wzorów na podstawie sztywnych zasad.

Rozwój uczenia maszynowego do analizy obrazu doznał przyspieszenia w latach siedemdziesiątych i osiemdziesiątych. Postępy w mocy obliczeniowej komputerów pozwoliły trenować i korzystać z bardziej złożonych, wielowarstwowych perceptronów.


Perceptrony wielowarstwowe to jeden z najpopularniejszych typów sieci neuronowych. Składa się z warstwy wejściowej i wyjściowej oraz co najmniej jednej ukrytej warstwy. W porównaniu z Perceptronem Rosenblatta składa się z warstw w pełni połączonych, w których każdy neuron danej warstwy jest połączony ze wszystkimi neuronami warstw sąsiednich, oraz korzysta z metod propagacji wstecznej pozwalającej na wydajny trening wszystkich warstw sieci i nieliniowych funkcji aktywacyjnych takich jak funkcja sigmoidalna, dzięki którym perceptron wielowarstwowy o odpowiedniej liczbie neuronów może przybliżać dowolną ciągłą funkcję z dowolną dokładnością [18, 10].

Równolegle do sieci z warstwami w pełni połączonymi rozwijane były sieci inspirowane innymi strukturami mózgu, opisanymi przez Hubela i Wieselą w latach pięćdziesiątych i sześćdziesiątych, w których neurony kory wzrokowej kota są aktywowane małymi obszarami pola widzenia [11]. Na podstawie tych badań Kunihiko Fukushima opracował i opublikował w 1980 roku Neocognitron [8]. W tej sieci wystąpiły dwa nowe rodzaje warstw. Warstwa S, znana później jako warstwa konwolucyjna, w której każdy neuron jest połączony z fragmentem poprzedniej warstwy, oraz warstwa C, również zbierająca dane z fragmentu poprzedniej warstwy, działająca jak warstwa poolingowa.


Jednym z najważniejszych wczesnych modeli sieci konwolucyjnych jest opracowany przez Yanna LeCunna i współpracowników LeNet, którego pierwsza wersja została opublikowana w 1990 roku [7]. Była to pierwsza sieć konwolucyjna trenowana algorytmami wstecznej propagacji, zastosowana do rozpoznawania ręcznie pisanych cyfr z kodów pocztowych z bazy danych dostarczonej przez United States Postal Service. Według LeCunna mniejsza w porównaniu do modeli z w pełni połączonymi warstwami zwiększała zdolność sieci do generalizacji [14]. W 1995 roku powstała piąta wersja LeNet, w której część konwolucyjna przekazywała dane do warstw w pełni połączonych. LeNet5 klasyfikował obrazy

ze standardowego zbioru ręcznie pisanych cyfr MNIST z błędem testowym 0.9%, najmniejszym ze wszystkich istniejących w tym czasie metod [17]. Ten model pozwolił zautomatyzować szereg procesów w systemach pocztowych i bankowych [15, 16].

Kolejny przełom w dziedzinie sieci konwolucyjnych nastąpił kiedy do trenin- gu sieci zaczęto wykorzystywać procesory graficzne [22]. Umożliwiło to wyko- rzystanie większych i głębszych sieci które mogły rozwiązywać bardziej złożo- ne problemy. AlexNet, jedna z pierwszych sieci trenowanych z wykorzystaniem procesorów graficznych, opracowana przez Alexa Krizhevskiego i współpracow- ników, mogła klasyfikować obrazy do tysiąca klas [13]. AlexNet miał strukturę podobną do LeNetu, z częścią konwolucyjną i w pełni połączoną, ale posiadał więcej warstw o większej ilości neuronów (Rysunek 2). Głębokie sieci konwolu- cyjne trenowane z wykorzystaniem procesorów graficznych stały się standardową najczęściej wykorzystywaną architekturą sieci w zadaniach związanych z analizą obrazów.



Rysunek 1: Schemat architektury sieci LeNet1, z pracy [17].



Rysunek 2: Porównanie architektury sieci LeNet-5 i AlexNet. Źródło: Cmglee, CC BY-SA 4.0, <https://creativecommons.org/licenses/by-sa/4.0>, via Wikimedia Commons.

Detekcja obiektów to zadanie bardziej złożone od klasyfikacji obrazów. Na danym obrazie może występować duża liczba obiektów należących do różnych klas, które trzeba sklasyfikować oraz wykryć ich położenie. Bounding Box Regression jest elementem wielu metod wykrywania obiektów.

Sieć R-CNN opublikowana w 2016 roku najpierw generuje dużą liczbę propozycji regionów zawierających obiekty, a następnie przekazuje każdy z nich do modułu składającego się z części konwolucyjnej i liniowej przeprowadzającej klasyfikację. Po klasyfikacji granice każdego z rejonów są modyfikowane przez właściwy dla klasy moduł BBR na podstawie wyniku zwróconego przez część konwolucyjną modułu klasyfikującego [9].

W sieci YOLO z 2015 roku zadanie Bounding Box Regression jest integralną częścią. Sieć dzieliła obraz na 49 równych części, w każdej z nich na podstawie całego obrazu przeprowadzając regresję dla dwóch kształtów ramek ograniczających oraz klasyfikację, zwracając przewidzianą klasę obiektu i ramkę o największym współczynniku pewności [19]. Sieć YOLO jest szeroko wykorzystywana i stale rozwijana, w 2024 roku została opublikowana sieć YOLO11 [1], a w pracach [5] i [25] wykorzystano odpowiednio z wersji YOLO8 i YOLO5.

3 Metodyka

3.1 Model


Sieć wraz z wykorzystanymi zbiorami danych i wynikami jest dostępna w publicznym repozytorium pod adresem <https://github.com/andrzej-oreszczuk/bounding-box-regression-release.git>

Model przewiduje ramkę ograniczającą obiekt na obrazie korzystając z wycinka obrazu zawierającego dany obiekt. Składa się z części konwolucyjnej, opisanej w sekcji 3.1.1, otrzymującej czarno-biały przeskalowany do rozmiaru 218 na 218 wycinek obrazu zawierający obiekt, mechanizmu uwagi, opisanego w sekcji 3.1.2, otrzymującego dane z części konwolucyjnej, oraz części liniowej, opisanej w sekcji 3.1.3, otrzymującej dane z modułu uwagi i zwracającej przewidziane relatywne położenie czterech krawędzi ramki ograniczającej na wejściowym wycinku (Rysunek 3) [16].

3.1.1 Część konwolucyjna

Część konwolucyjna składa się z dziesięciu warstw z 64 kanałami wyjściowymi i jądrem o wymiarze 3x3 rozdzielonymi funkcjami aktywacyjnymi ReLU [16]. Po pierwszej i każdych trzech kolejnych warstwach konwolucyjnych, umieszczone jest pięć warstw poolingowych które mogą być aktywowane lub dezaktywowane w zależności od wybranej konfiguracji modelu, dzięki czemu można zmieniać pole recepcyjne neuronów w ostatniej warstwie konwolucyjnej. W pracy zbadano pięć konfiguracji sieci:

1. Wszystkie pięć warstw poolingowych jest aktywne. ostatnia warstwa konwolucyjna składa się z jednego neuronu o polu recepcyjnym 218, obejmującym cały obraz wejściowy. Moduł uwagi jest nieaktywny, a dane z części konwolucyjnej są przekazywane bezpośrednio do części liniowej.
2. Aktywne są pierwsze cztery warstwy poolingowe, ostatnia warstwa konwolucyjna ma wymiary 4x4 a jej neurony mają pole recepcyjne wielkości 170 i krok 16.
3. Aktywne są pierwsze trzy warstwy poolingowe, ostatnia warstwa konwolucyjna ma wymiary 14x14 a jej neurony mają pole recepcyjne wielkości 114 i krok 8.
4. Aktywne są pierwsze dwie warstwy poolingowe, ostatnia warstwa konwolucyjna ma wymiary 38x38 a jej neurony mają pole recepcyjne wielkości 70 i krok 4.
5. Aktywna jest tylko pierwsza warstwa poolingowa, ostatnia warstwa konwolucyjna ma wymiary 94x94 a jej neurony mają pole recepcyjne wielkości 40 i krok 2.



Rysunek 3: Schemat architektury sieci.

3.1.2 Moduł uwagi

Zastosowano mechanizm uwagi z jedną głową uwagi ze strukturą opisaną w pracy [4]. Moduł uwagi zawiera jedną głowę uwagi z liczbą parametrów 64, równą liczbie kanałów wyjściowych części konwulucyjnej. Przekształca on dane wyjściowe z ostatniej warstwy konwulucyjnej do jednego wektora o długości równej liczbie kanałów. Moduł oblicza iloczyn skalarny między wektorem parametrów głowy uwagi i danymi wyjściowymi części konwulucyjnej, którego wynikiem jest wektor energii zakodowanych przez część konwulucyjną danych składający się z jednej wartości energii dla każdego neuronu wyjściowego. Wektor energii jest dalej normalizowany przez funkcję softmax. W wyniku normalizacji powstaje wektor wag każdego z neuronów z pozytywnymi wartościami sumującymi się do jedności, w którym neurony o większej energii otrzymują większą wagę. Moduł uwagi zwraca wektor długości 64 będący ważoną zgodnie z obliczonym wektorem wag sumą danych z neuronów wyjściowych części konwulucyjnej, w której dominują dane z neuronów o najwyższej energii, a więc najbardziej zgodne z wektorem parametrów głowy uwagi.

3.1.3 Część liniowa

Część liniowa składa się z dwóch warstw liniowych rozdzielonych funkcją aktywacyjną ReLU. Pierwsza warstwa otrzymuje wektor długości 64 z danymi z modułu uwagi lub bezpośrednio z części konwulucyjnej w przypadku modelu o polu recepcyjnym 218. Druga warstwa zwraca cztery liczby oznaczające przewidziane odległości czterech krawędzi ramki od środka wejściowego wycinka jako ułamek jego wymiarów.

3.2 Trening

3.2.1 Przygotowanie danych

Zbiory danych do treningu sieci zostały stworzone korzystając z precyzyjnie oznaczonych zbiorów danych w formacie YOLO.

Ponieważ sieć ma przewidywać precyzyjne ramki ograniczające na podstawie niedokładnych oznaczeń wykonanych przez człowieka zasymulowano ręczne oznaczenie przez człowieka obiektów przez losowe odsunięcie każdej z czterech krawędzi prawdziwej ramki ograniczających od jej środka; prawą krawędź odsuwano w prawo, lewą w lewo, dolną w dół, górną w górę. Dla każdej z krawędzi losowano zgodnie z rozkładem jednostajnym wartość r z zakresu $(0.1, 0.6)$. Krawędź przesuwano o wartość $d = r \cdot s \cdot w$, gdzie s to zmienna o początkowej wartości 0.95 a w to odpowiedni wymiar prawdziwej ramki; wysokość dla górnej i dolnej krawędzi, szerokość dla lewej i prawej. Następnie sprawdzano czy wygenerowane położenie krawędzi mieści się wewnątrz obrazu: jeśli względne położenie przesuniętej krawędzi obiektu na obrazie nie należało do zakresu $(0.01, 0.99)$ oryginalnego obrazu, losowanie przesunięcia było powtarzane z wartością s pomnożoną przez 0.95, aby umożliwić i przyspieszyć generację danych w przypadku obiektów, których krawędzie znajdują się bardzo blisko brzegów obrazu. W wyniku losowania mamy zatem

$$0.095w \leq d \leq 0.57w$$

Przy generacji danych nie sprawdzano czy środek wygenerowanej ramki znajduje się wewnątrz obiektu, ponieważ dla użytego zakresu losowania przesunięć to założenie będzie zawsze spełnione.

Fakt 3.1. *Załóżmy że mamy dwa punkty $x_1 < x_2 \in \mathbb{R}$. Niech $w = x_2 - x_1$ będzie odległością x_1 i x_2 . Po przesunięciu prawego punktu w prawo o wartość d_p a lewego w lewo o wartość d_l spełniające*

$$0.095w \leq d_p \leq 0.57w$$

oraz

$$0.095w \leq d_l \leq 0.57w,$$

środek nowego odcinka znajdzie się pomiędzy x_1 i x_2 .

Dowód. Środek nowego odcinka znajdzie się w punkcie o współrzędnej

$$x_s = (x_1 - d_l + x_2 + d_p)/2$$

Dowód będzie nie wprost. Aby środek znalazł się poza odcinkiem łączącym x_1 i x_2 musiałoby zajść:

$$\begin{aligned} x_s > x_2 \quad \text{lub} \quad x_s < x_1, \\ (x_1 - d_l + x_2 + d_p)/2 > x_2 \quad \text{lub} \quad (x_1 - d_l + x_2 + d_p)/2 < x_1, \end{aligned}$$

$$d_p - d_l > x_2 - x_1 = w \quad \text{lub} \quad d_p - d_l < x_1 - x_2 = -w,$$

$$d_p > w + d_l \quad \text{lub} \quad d_l > w + d_p.$$

Ale mamy przecież

$$0.095w \leq d_p \leq 0.57w$$

oraz

$$0.095w \leq d_l \leq 0.57w$$

co daje sprzeczność. $\square$

Analogiczne rozumowanie można przeprowadzić dla górnej i dolnej granicy oraz wysokości ramki.

Podsumowując, ponieważ krawędzie były przesuwane o co najwyżej 0.57 wysokości lub szerokości, to, biorąc pod uwagę powyższe rozumowanie, nie mogło to spowodować przesunięcia środka wygenerowanej ramki poza granice oryginalnej ramki.

Do sieci neuronowej przekazywany jest wycinek obrazu ograniczony otrzymanymi w wyżej opisany sposób granicami przeskalowany do wymiarów 218 na 218.

3.2.2 Parametry treningu

Do trenowania sieci wykorzystano optymalizator ADAM (ang. *ADaptive estimation of first-order and second-order Moments* [12]), ze stałą wielkością kroku uczenia 0.00001. Rozmiar porcji danych wsadu wynosił 128. Funkcją straty był błąd średniokwadratowy między wynikiem zwróconym przez sieć a poprawnym wynikiem obliczonym na podstawie anotacji (patrz sekcja 4.1).


Warunkowa struktura modelu z aktywowanymi warstwami poolingowymi pozwoliła na trenowanie wersji modelu zaczynając od wag otrzymanych przy treningu sieci w konfiguracji z innym polem recepcyjnym. Zaobserwowano poprawę wyników treningu dzięki wykorzystaniu tej metody (patrz sekcja 4.2.1).

3.3 Zbiory danych

Do treningu sieci wykorzystano dwa zbiory rzeczywistych danych, przedstawiające zdjęcia mikroskopowe gran oraz skany hiszpańskich manuskryptów. Do wstępnego treningu umożliwiającego uzyskanie lepszych wyników treningu na właściwych danych stworzono prosty syntetyczny zbiór danych. Użycie danych syntetycznych do wstępnego treningu okazało się korzystne z punktu widzenia treningu sieci na obu zbiorach danych rzeczywistych. W obu przypadkach zaobserwowano bardzo powolną zbieżność treningu, jeśli rozpoczął się on od danych rzeczywistych. Szybkość zbieżności uległa znacznej poprawie kiedy trening rozpoczął się od wstępnego treningu na danych syntetycznych, trwającego do osiągnięcia straty mniejszej niż 0.001.

3.3.1 Dane syntetyczne

Zbiór prostych syntetycznych danych (patrz Rysunek 4), ze zbiorem treningowym zawierającym 860 obrazów i 2642 obiekty. Powstał przez zmodyfikowanie zbioru danych zdjęć mikroskopowych liści [2]. Oznaczone obiekty zostały zastąpione wpisanymi w ramki ograniczające prostymi figurami o wylosowanych parametrach; owalami, czworokątami albo skrzyżowanymi liniami.




Rysunek 4: Przykładowe obrazy ze zbioru danych syntetycznych wykorzystane przy wstępnym treningu, z narysowanymi niebieskimi ramkami ograniczającymi obiektów.

3.3.2 Manuskrypty

Zbiór skanów manuskryptów hiszpańskojęzycznych, w którym obiektami są wystąpienia w tekście słowa "Lacandon", zaczerpnięty z pracy [25]. Od 2022 roku grupa mojego promotora we współpracy z Dr Hectorem Callerosem z Ośrodka Studiów Amerykańskich UW prowadzi eksplorację obszernego zbioru około 2000 obrazów zdigitalizowanych rękopisów z Głównego Archiwum Indii w Sewilli (Hiszpania). Rękopisy te to listy z XVII wieku pisane przez arystokrację hiszpańską zarządzającą kolonią w Ameryce Łacińskiej. Dokumenty te dotyczą Lacandon, rdzennego ludu który doświadczył przymusowych przesiedleń pod rządami kolonialnymi Hiszpanii.


Obrazy zawierały podwójne strony rękopisów. Zostały one podzielone na cztery części, tak że każdy rozważany dalej obraz zawiera połowę strony. Za pomocą technik detekcji obrazu zmapowane zostały w tych rękopisach słowa kluczowe centralne dla badań Dr Callerosa. Jednym z nich było "Lacandon" i jego warianty morfologiczne. Obrazy zostały losowo podzielone na zbiór treningowy zawierający 207(70%) obrazów i 221(70%) obiektów, testowy zawierający 46(15%) obrazów i 48(15%) obiektów i walidacyjny zawierający 46(15%) obrazów i 47(15%) obiektów. Dane podzielono przydzielając losowo do zbiorów obiekty w ten sposób aby wszystkie obiekty znajdujące się na dowolnym z obrazów należały do tego samego zbioru.



Rysunek 5: Dwa przykładowe obrazy ze zbioru manuskryptów, z narysowanymi niebieskimi ramkami ograniczającymi obiektów. Każdy obraz zawiera połowę strony oryginalnego manuskryptu.

3.3.3 Grana

Zbiór zdjęć uzyskanych przy użyciu mikroskopii elektronowej w którym obiektami są grana, czyli struktury występujące w chloroplastach, zaczerpnięto z pracy [5]. Wykorzystano tylko obiekty z ramkami nienachodzącymi na brzegi obrazów, które zostały losowo podzielone na zbiór treningowy zawierający 171(60%) obrazów i 2251(59%) obiektów, testowy zawierający 56(20%) obrazów i 804(21%) obiekty i walidacyjny zawierający 56(20%) obrazów i 770(20%) obiektów. Dane podzielono przydzielając losowo do zbiorów obiekty w ten sposób aby wszystkie obiekty znajdujące się na dowolnym z obrazów należały do tego samego zbioru.



Rysunek 6: Przykładowe obrazy ze zbioru zdjęć mikroskopowych przedstawiających grana, z narysowanymi niebieskimi ramkami ograniczającymi obiektów.

4 Wyniki

4.1 Metryki i funkcja straty

W czasie treningu używano funkcji straty MSE (ang. *mean square error*, błąd średniokwadratowy)— średni kwadrat różnicy między odpowiedzią sieci a prawidłowym celem obliczonym na podstawie wartości etykiety:

Niech g_i oznacza wektor prawdziwych obserwacji (ang. *ground truth*), czyli wartość zgodną z etykietą, składający się z czterech wartości oznaczających położenie granic etykiety na wycinku obrazu otrzymanym przez sieć (g_{gi} — położenie górnej krawędzi, g_{di} — położenie dolnej krawędzi, g_{li} — położenie lewej krawędzi, g_{pi} — położenie prawej krawędzi) a p_i oznacza wektor wartości predykowanych przez sieć (p_{gi} — położenie górnej krawędzi, p_{di} — położenie dolnej krawędzi, p_{li} — położenie lewej krawędzi, p_{pi} — położenie prawej krawędzi) (w obu przypadkach indeks i przebiega obserwacje z próby uczącej o wielkości N). Wtedy wartość błędu MSE predykcji dla danej próby uczącej wielkości N wynosi:

$$\text{MSE}(g, p) = \frac{1}{N} \sum_{i=1}^N ((g_{gi} - p_{gi})^2 + (g_{di} - p_{di})^2 + (g_{li} - p_{li})^2 + (g_{pi} - p_{pi})^2) / 4$$

Ten błąd dotyczy średniej kwadratów różnic między względnymi położeniami krawędzi ramki wewnątrz wycinka obrazu analizowanego przez sieć, więc nie ma łatwej intuicyjnej interpretacji dla człowieka.

Do łatwiejszej oceny jakości przewidywań wytrenowanych modeli w zadaniu przewidywania ramek ograniczających użyto następujących metryk, obliczonych na podstawie wyrażonych w pikselach współrzędnych położenia prawdziwej i przewidzianej ramki ograniczającej dany obiekt na całym obrazie na którym się znajduje:

- MAE (ang. *mean absolute error*)— średnie bezwzględne przesunięcie położenia czterech krawędzi przewidzianej ramki względem krawędzi prawdziwej ramki w pikselach. Dla zbioru zawierającego N obiektów:

$$\text{MAE}(g, p) = \frac{1}{N} \sum_{i=1}^N (|g_{gi} - p_{gi}| + |g_{di} - p_{di}| + |g_{pi} - p_{pi}| + |g_{li} - p_{li}|) / 4$$

- MAE szerokości— średnia bezwzględna różnica między szerokością przewidzianej ramki a prawdziwej ramki w pikselach. Dla zbioru zawierającego N obiektów:

$$\text{MAE}_s(g, p) = \frac{1}{N} \sum_{i=1}^N |g_{di} - g_{gi} - p_{di} + p_{gi}|$$

- MAE wysokości— średnia bezwzględna różnica między wysokością przewidzianej ramki a prawdziwej ramki w pikselach. Dla zbioru zawierającego N obiektów:

$$\text{MAE}_w(g, p) = \frac{1}{N} \sum_{i=1}^N |g_{pi} - g_{li} - p_{pi} + p_{li}|$$

- MAPE (ang. *mean absolute percent error*) szerokości— średnia bezwzględna różnica między szerokością przewidzianej ramki a prawdziwej ramki jako procent szerokości prawdziwej ramki. Dla zbioru zawierającego N obiektów:

$$\text{MAPE}_s(g, p) = \frac{100\%}{N} \sum_{i=1}^N |g_{pi} - g_{li} - p_{pi} + p_{li}| / (g_{pi} - g_{li})$$

- MAPE wysokości— średnia bezwzględna różnica między wysokością przewidzianej ramki a prawdziwej ramki jako procent wysokości prawdziwej ramki. Dla zbioru zawierającego N obiektów:

$$\text{MAPE}_w(g, p) = \frac{100\%}{N} \sum_{i=1}^N |g_{di} - g_{gi} - p_{di} + p_{gi}| / (g_{di} - g_{gi})$$

Do oceny poprawności działania metody przewidującej kąt obrotu gran, opisanej w sekcji 4.3.2, użyto metryki dokładności:

- Dokładność (ang. *accuracy*)— stosunek liczby obiektów dla których metoda poprawnie przewidziała kąt obrotu do liczby przeanalizowanych obiektów.


4.2 Manuskrypty

Przetestowano działanie pięciu wariantów sieci trenując je na zbiorze manuskryptów.

Dla każdego wariantu sieci przeprowadzono wstępny trening na zbiorze syntetycznym do uzyskania straty mniejszej niż 0.001 a następnie trening na rzeczywistych danych z dynamiczną generacją danych, zgodnie z procedurą losowania opisaną w sekcji 3.2.1, na zbiorze manuskryptów trwający 60000 epok lub do czasu kiedy strata na zbiorze walidacyjnym przestaje spadać. Wyniki przedstawiono na Rysunku 7 i w Tabeli 1. Najlepszy wynik na zbiorze testowym osiągnęła sieć w konfiguracji z jednym neuronem wyjściowym części konwolucyjnej z polem recepcyjnym 218, bez modułu uwagi. W pozostałych konfiguracjach nastąpiło przeuczenie sieci. Dla sieci w wersji 5 z polem recepcyjnym 40 nie otrzymano wyników ponieważ nie uzyskano zbieżności treningu już na etapie wstępnego treningu na zbiorze danych syntetycznych.

Tabela 1: Wyniki treningu na zbiorze manuskryptów.

wersja sieci (pole recepcyjne)	1 (218)	2 (170)	3 (114)	4 (70)	5 (40)
najlepsza epoka	58565	5770	2190	16620	—
strata na zbiorze testowym	0.00125	0.00146	0.00168	0.0041	—
strata na zbiorze walidacyjnym	0.00118	0.00137	0.00190	0.0036	—



Rysunek 7: Przebieg treningu czterech wersji sieci na zbiorze manuskryptów.

Wyniki treningu sieci są najlepsze dla sieci w konfiguracji nr 1 oraz są coraz gorsze wraz ze zmniejszaniem pola recepcyjnego sieci w kolejnych wersjach, a wersja nr 5 z najmniejszym polem recepcyjnym 40 nie osiągnęła zbieżności nawet przy treningu na prostych danych syntetycznych. Można hipotetyzować że wynika to częściowo z użycia modułu uwagi, który wszystkie dane z części konwolucyjnej sieci przekształca w jeden wektor długości 64, i ma jedynie 64 parametry. Może to powodować mało wydajny transfer informacji z części konwolucyjnej do części liniowej w przypadku konfiguracji sieci o mniejszym polu recepcyjnym i większej liczbie neuronów wyjściowych, i skutkować słabą jakością działania sieci. Tą hipotezę można zbadać w przyszłych badaniach, wychodzących poza zakres tej pracy.

4.2.1 Transfer wag


Zaobserwowano lepsze wyniki treningu wersji sieci w której nie jest aktywny moduł uwagi. Korzystając z tego że konfiguracje sieci mają podobną strukturę części konwolucyjnej z taką samą liczbą warstw i parametrów (ponieważ różnią się tylko liczbą warstw poolingowych które nie mają parametrów) przetestowano trening sieci w konfiguracji 2 korzystając z uzyskanych wag wersji 1. W tym celu rozpoczęto trening sieci w wersji 2 z wszystkimi wagami równymi wagom uzyskanym w treningu sieci w wersji 1, przy czym w wersji 1 moduł uwagi nie jest aktywny, dlatego jego parametry nie są zoptymalizowane.

W tych warunkach na początku treningu część konwolucyjna sieci była bliska wytrenowania, a w czasie treningu musiały zostać zoptymalizowane głównie parametry modułu uwagi, które miały losowe parametry. Przy tym treningu nie wystąpiło przetrenowanie, a sieć osiągnęła lepszy wynik na zbiorze testowym. Następnie powtórzono tą samą procedurę trenując sieć w konfiguracji 1 korzystając z uzyskanych w ten sposób wag sieci w konfiguracji 2, uzyskując najmniejszy błąd na zbiorze testowym. Aby sprawdzić czy poprawa wyników wynika z dłuższego łącznego czasu treningu przeprowadzono też odpowiednio dłuższy trening sieci w konfiguracji 1 trwający 180000 epok.

Wyniki przedstawiono w Tabeli 2 a przebieg treningu na Rysunku 8.

Tabela 2: Wyniki treningu na zbiorze manuskryptów przy zastosowaniu transferu wag

wersja sieci	Konfiguracja nr 2 z transferem wag	Konfiguracja nr 1 z transferem wag	Konfiguracja nr 1 trenowana dłużej
najlepsza epoka	59565	57250	177390
strata na zbiorze testowym	0.00138	0.00115	0.00120
strata na zbiorze walidacyjnym	0.00110	0.00110	0.00101



Rysunek 8: Przebieg treningu sieci na zbiorze manuskryptów z wykorzystaniem transferu wag oraz dłuższego treningu sieci w wersji 1.

Wyniki sieci trenowanej dłuższym treningiem na zbiorze testowym są nieznacznie gorsze od treningu z wykorzystaniem transferu wag (różnica na poziomie 0.00005, 4%), za to jej wyniki na zbiorze walidacyjnym są lepsze, przy czym różnica w wynikach na zbiorze walidacyjnym jest około dwa razy większa (różnica na poziomie 0.00009, 8%). Sugeruje to że ten wynik może być spowodowany losowymi fluktuacjami przebiegu treningu, a transfer wag nie poprawia jakości treningu.

Do oceny działania sieci w sekcji 4.2.2 wykorzystano sieć, która otrzymała najlepszy wynik na zbiorze testowym, to jest sieć w konfiguracji nr 1 wytrenowaną z wykorzystaniem transferu wag. Skuteczność treningu z transferem wag nie została jednoznacznie określona, więc w dalszym treningu sieci na zbiorze zdjęć gran przetestowano sieć wytrenowaną obiema metodami; z transferem wag oraz odpowiednio dłuższym treningiem bez transferu wag (patrz sekcja 4.3).

4.2.2 Benchmarking

Aby porównać działanie sieci z dostępnymi metodami wytrenowano na zbiorze manuskryptów sieć YOLO11 w wersji yolo11n. Najmniejsza wersja YOLO11, yolo11n, ma 2,62 milionów parametrów [3], a sieć którą rozważam w tej pracy ma około 334 tysiące parametrów.

Sieć YOLO nie przewiduje ramek ograniczających dla podanych obiektów, zamiast tego wykrywa położenie wszystkich obiektów danej klasy na obrazie i znajduje ich ramki ograniczające, dlatego nie jest możliwe bezpośrednie porów-


nanie wyników działania badanej sieci i modelu YOLO.

Aby móc porównać działanie YOLO do badanej sieci dla każdego z obiektów znaleziono w ramach przewidzianych przez model YOLO ramkę ograniczającą której środek znajduje się geometrycznie najbliżej środka prawdziwej ramki ograniczającej. W przypadku niektórych obiektów model YOLO może nie wykryć obiektu i nie przewidzieć ramki ograniczającej dany obiekt, dlatego dodatkowo sprawdzono czy środek znalezionej najbliższej przewidzianej ramki znajduje się w środku prawdziwej ramki. Jeśli tak, uznawano tą ramkę za przewidzianą przez yolo dla tego obiektu, a jeśli nie uznawano że model YOLO nie przewidział dla tego obiektu ramki i nie uwzględniano tego obiektu przy obliczaniu metryk działania modelu.

Dla uzyskanych w ten sposób przewidzianych przez model YOLO oraz najlepszą wersję badanego modelu ramek ograniczających obiektów ze zbioru testowego obliczono szereg metryk przedstawionych w Tabeli 3. Metryki przewidzianych przez model YOLO ramek są znacząco lepsze, średni błąd bezwzględny położenia każdej z czterech krawędzi ramki wynosi 2.33 piksela, prawie trzy razy mniej niż badanej sieci. Model YOLO nie wykrył dwóch z 48 obiektów w zbiorze testowym (4%). Przykładowe obiekty z narysowanymi przewidzianymi ramkami pokazano na Rysunku 9.

Tabela 3: Porównanie przewidzianych ramek ograniczających. Wykorzystane metryki opisano w sekcji 4.1

model	MAE [px]	MAE szerokości [px]	MAE wysokości [px]	MAPE szer. [%]	MAPE wys. [%]
yolo11n	2.33	3.8	3.61	1.2	4.7
BBR	6.82	12.17	6.38	4.2	7.7



Rysunek 9: Przykładowe obiekty ze zbioru manuskryptów z narysowanymi ramkami ograniczającymi. Zielona ramka to prawdziwa ramka ograniczająca, niebieska to ramka przewidziana przez badaną sieć BBR, a czerwona to ramka przewidziana przez sieć YOLO.

4.3 Grana

Ze względu na ograniczone zasoby obliczeniowe trening na zbiorze gran trwał dużo dłużej niż na zbiorze manuskryptów, dlatego na zbiorze gran wytrenowano jedynie sieć w konfiguracji 1, która osiągnęła najlepsze wyniki na zbiorze manuskryptów. Przetestowano trening zgodnie z procedurą transferu wag, opisaną w sekcji 4.2.1, oraz dłuższy trening bez transferu wag.


Wytrenowano sieć w konfiguracji 1 z transferem wag na zbiorze zdjęć gran. Przeprowadzono wstępny trening sieci w wersji 1 na zbiorze syntetycznym do uzyskania straty mniejszej niż 0.001, a następnie trening na zbiorze zdjęć chloroplastów trwający 6800 epok, z dynamiczną generacją danych zgodnie z procedurą losowania opisaną w sekcji 3.2.1, z dodatkową augmentacją danych przez zastosowanie losowych odbić i obrotów o 90 stopni. Następnie wytrenowano sieć w wersji 2 rozpoczynając od uzyskanych wag, który trwał 4400 epok, kiedy przestano obserwować postępy treningu. Rozpoczynając od uzyskanych w ten sposób wag sieci wersji 2 wytrenowano przez 2000 epok sieć w wersji 1, uzyskując najmniejszą stratę na zbiorze testowym.

Aby sprawdzić efektywność metody transferu wag przeprowadzono też odpowiednio dłuższy trening sieci w konfiguracji 1. Przy tym treningu nastąpiło przetrenowanie sieci, a sieć uzyskała najmniejszą stratę na zbiorze walidacyjnym po 7228 epokach.

Wyniki przedstawiono w Tabeli 4 a przebieg treningu na Rysunku 10.

Tabela 4: Wyniki treningu na zbiorze zdjęć gran przy zastosowaniu transferu wag

wersja sieci	Konfiguracja nr 2 z transferem wag	Konfiguracja nr 1 z transferem wag	Konfiguracja nr 1 trenowana dłużej
najlepsza epoka	3595	1835	7228
strata na zbiorze testowym	0.00195	0.00171	0.00179
strata na zbiorze walidacyjnym	0.00224	0.00198	0.00205



Rysunek 10: Przebieg treningu sieci na zbiorze manuskryptów z wykorzystaniem transferu wag oraz dłuższego treningu sieci w wersji 1.

Wyniki działania sieci wytrenowanej z wykorzystaniem transferu wag są znacznie lepsze od wyników sieci trenowanej dłużej. Różnica na zbiorze testowym wynosi 0.00008 (5%), a walidacyjnym 0.00007 (4%). Różnica jest nieznaczna, jednak w przypadku treningu z transferem wag nie zaobserwowano przetrenowania, co sugeruje że dalszy trening mógłby zwiększyć tą różnicę. Jeśli trening z transferem wag rzeczywiście poprawia wyniki treningu, może to wynikać z zaburzenia przy nowym starcie treningu, które pozwala sieci wybić się z lokalnego minimum funkcji straty w przestrzeni parametrów. To zachowanie można zbadać w przyszłych badaniach, wychodzących poza zakres tej pracy.


Do oceny działania sieci w sekcji 4.3.1 wykorzystano sieć, która otrzymała najlepszy wynik na zbiorze testowym, to jest sieć w konfiguracji nr 1 wytrenowaną z wykorzystaniem transferu wag.

4.3.1 Benchmarking

Przeprowadzono porównanie wyników działania sieci z modelem yolo11n zgodnie z procedurą opisaną w sekcji 4.2.2. Metryki przedstawiono w Tabeli 5. Sieć yolo nie przewidziała ramki dla 74 z 804 obiektów w zbiorze testowym (9%). Przykładowe obiekty z narysowanymi przewidzianymi ramkami pokazano na Rysunku 11.

Tabela 5: Porównanie przewidzianych ramek ograniczających dla zbioru gran. Wykorzystane metryki opisano w sekcji 4.1


model	MAE [px]	MAE szerokości [px]	MAE wysokości [px]	MAPE szer. [%]	MAPE wys. [%]
yolo11n	30.4	50.9	50.0	12.0	12.3
BBR	26.0	34.5	35.5	6.8	7.1



Rysunek 11: Przykładowe obiekty ze zbioru zdjęć gran z narysowanymi ramkami ograniczającymi. Zielona ramka to prawdziwa ramka ograniczająca, niebieska to ramka przewidziana przez badaną sieć BBR, a czerwona to ramka przewidziana przez sieć YOLO.

Na tym zbiorze działanie stworzonego modelu BBR jest znacznie lepsze niż modelu YOLO, mimo tego że użyta sieć YOLO jest około 1000 razy bardziej pojemna od sieci badanej w tej pracy.

Może to wynikać z tego że na analizowanych obrazach znajduje się wiele gęsto ułożonych a nawet stykających się i trudnych do rozróżnienia obiektów. Może to powodować w przypadku modelu YOLO zakwalifikowanie jednego grana jako dwa osobne i przewidzenie dwóch zbyt małych ramek albo też zakwalifikowanie dwóch gran jako jedno i przewidzenie zbyt dużej ramki (patrz Rysunek 12). W takich przypadkach dodatkowa informacja w postaci przybliżonej ramki oznaczonej przez człowieka pozwala modelowi BBR uniknąć tego błędu. W przypadku zbioru manuskryptów szukane obiekty są rzadko rozmieszczone i łatwe do rozróżnienia, więc ta informacja w mniejszym stopniu usprawnia działanie sieci, dlatego większy i bardziej dopracowany model YOLO przewiduje ramki z większą precyzją.




Rysunek 12: Przykładowe obiekty ze zbioru zdjęć gran z narysowanymi ramkami ograniczającymi dla których sieć yolo przewidziała znacząco nieprawidłową ramkę. Zielona ramka to prawdziwa ramka ograniczająca, niebieska to ramka przewidziana przez badaną sieć BBR, a czerwona to ramka przewidziana przez sieć YOLO.

4.3.2 Kąt obrotu

Przetestowano zastosowanie sieci do wykrywania kąta obrotu gran na zdjęciach. Jest to jedno z zadań wykonywanych w czasie analizy gran w pracy [5]. Ułożenie danego grana w pozycji poziomej ułatwia analizę gęstości ułożenia tylakoidów, czyli struktur widocznych jako prążki tworzące grana, co jest jednym z parametrów określanych przy analizie gran. W pracy [5] autorzy pokazali, że nawet po zastosowaniu specjalistycznego narzędzia do estymacji kąta, prosta algorytmiczna procedura korekcji wyestymowanego kąta w zakresie $\pm 10^\circ$ w oparciu o minimalizację powierzchni prostokątnej otoczki poprawia jakość estymacji. Stworzyło to motywację dla niniejszego podrozdziału.

Wytrenowaną sieć na zbiorze zdjęć chloroplastów wykorzystano do określania kąta obrotu gran przez obracanie obrazów i znajdowanie takiego kąta obrotu, dla którego sieć przewiduje ramkę ograniczającą o najmniejszej powierzchni. Przykładowe obrócone obiekty przedstawiono na Rysunku 13. Sprawdzono poprawność wyników przewidywania obrotów wybierając 200 losowych obiektów dla których wizualnie określono poprawność przewidzianego obrotu. Z 200 obiektów 114 (57%) zostało ocenione jako poprawnie obrócone do pionowej lub poziomej pozycji, tak więc dokładność działania metody wynosi 57%.



Rysunek 13: Przykładowe obiekty ze zbioru zdjęć gran obrócone o kąt wyestymowany przez minimalizację pola otoczki prostokątnej. Za poprawne należy uznać obiekty obrócone zarówno do poziomej jak i pionowej pozycji. Dla czytelności dorysowano po estymacji kąta prawdziwe ramki ograniczające dany obiekt.

W przypadku niektórych gran i kątów taka procedura powoduje wyjście grana poza granice przekazywanego do sieci wycinka obrazu, dlatego przetestowano też metodę wykrywania kąta w której do sieci przekazywany jest odpowiednio większy wycinek obrazu który będzie zawierał cały obiekt obrócony o dowolny kąt, jednak taka metoda dawała gorsze wyniki, porównywalne do losowych. Wynikało to z tego że sieć gorzej przewidywała ramki ograniczające bo otrzymywała wycinki obrazów na których obiekty były dużo mniejsze niż te otrzymywane w czasie treningu. Można rozważyć dotrenowanie sieci w takich warunkach, wybiega to jednak poza zakres tej pracy. Celem było pokazanie jak użyć *istniejącej* sieci BBR do estymacji kąta, a nie stworzenie wyspecjalizowanego narzędzia do estymacji kąta.

5 Wnioski

Celem pracy było stworzenie metody wykorzystującej głęboką sieć neuronową wykonującą zadanie Bounding Box Regression przewidującą ramki ograniczające obiekty na obrazach z wykorzystaniem przybliżonej nieprecyzyjnie oznaczonej ramki ograniczającej dany obiekt. Miało to poprawić precyzję przewidywania ramki ograniczającej w porównaniu do metod które nie otrzymują żadnej dodatkowej informacji o położeniu obiektu na obrazie.

W ramach pracy zbadano kilka wersji sieci wykonującej zadanie Bounding Box Regression o różnych polach recepcyjnych neuronów wyjściowych części konwolucyjnej. Najlepszą jakość przewidywań osiągnęła sieć o największym polu recepcyjnym obejmującym cały wejściowy obraz. Zaproponowano hipotezę że na ten wynik może wpływać zastosowanie modułu uwagi, który może powodować utratę informacji w przypadku sieci o mniejszym polu recepcyjnym i większej liczbie neuronów wyjściowych części konwolucyjnej.

Przetestowano działanie sieci na rzeczywistych zbiorach danych przedstawiających zdjęcia mikroskopowe gran oraz skany manuskryptów i porównano jakość ich przewidywań z najnowszą wersją modelu YOLO. W przypadku da-

nych przedstawiających skany manuskryptów jakość przewidywań była gorsza niż przewidywań modelu YOLO, a w przypadku danych biologicznych znacznie lepsza. Może to wynikać z tego że obrazy w użytym zbiorze danych biologicznych zawierają wiele gęsto ułożonych obiektów, które mogą być trudne do poprawnego odróżnienia, dlatego w tym przypadku dodatkowa informacja w postaci przybliżonej ramki ograniczającej pozwala badanej sieci osiągnąć lepsze rezultaty od zaawansowanej sieci YOLO o dużo większej liczbie parametrów.

Pokazano jak można wykorzystać sieć BBR do estymowania kąta obrotu gran na zdjęciach przez minimalizację pola powierzchni ich ramki ograniczającej.

Uzyskane wyniki wskazują na to, że metody podobne do tej przedstawionej w tej pracy mogą być użyteczne w zadaniach związanych z wykrywaniem obrazów, szczególnie w przypadku analizy danych biologicznych.

6 Podziękowania

Dziękuję mojemu promotorowi, doktorowi Szymonowi Nowakowskiemu, za wsparcie i cierpliwość.

Dziękuję doktorowi Przemysławowi Olbratowskiemu za udostępnienie narzędzia do analizy pola recepcyjnego sieci.

Praca częściowo sfinansowana przez Centrum Uczenia Maszynowego, Uniwersytet Warszawski (IDUB, Działanie I.3.7).

Bibliografia

- [1] 2024. URL: <https://docs.ultralytics.com/models/yolo11/>.
- [2] URL: <https://universe.roboflow.com/object-detection/stomata-cells>.
- [3] URL: <https://leaderboard.roboflow.com/>.
- [4] Dzmitry Bahdanau. “Neural machine translation by jointly learning to align and translate”. W: *arXiv preprint arXiv:1409.0473* (2014).
- [5] Alicja Bukat i in. “GRANA: Accelerating Chloroplast Grana Nanomorphology Analysis with Hybrid Intelligence (2024)”. W: *In preparation* ().
- [6] Angela Casado-García i in. “LabelStoma: A tool for stomata detection based on the YOLO algorithm”. W: *Computers and Electronics in Agriculture* 178 (2020), s. 105751. ISSN: 0168-1699. DOI: <https://doi.org/10.1016/j.compag.2020.105751>. URL: <https://www.sciencedirect.com/science/article/pii/S0168169920312977>.
- [7] Y. Le Cun i in. “Handwritten digit recognition with a back-propagation network”. W: *Advances in Neural Information Processing Systems 2*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1990, s. 396–404. ISBN: 1558601007.

- [8] Kuniyiko Fukushima. “Neocognitron: A Self-organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position”. W: *Biol. Cybernetics* 36 (1980), s. 193–202. DOI: <https://doi.org/10.1007/BF00344251>.
- [9] Ross Girshick i in. “Region-Based Convolutional Networks for Accurate Object Detection and Segmentation”. W: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 38.1 (2016), s. 142–158. DOI: 10.1109/TPAMI.2015.2437384.
- [10] Kurt Hornik, Maxwell Stinchcombe i Halbert White. “Multilayer feed-forward networks are universal approximators”. W: *Neural Networks* 2.5 (1989), s. 359–366. ISSN: 0893-6080. DOI: [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8). URL: <https://www.sciencedirect.com/science/article/pii/0893608089900208>.
- [11] WIESEL TN HUBEL DH. “Receptive fields of single neurones in the cat’s striate cortex”. W: *J Physiol.* 148.3 (1959), s. 574–591. DOI: 10.1113/jphysiol.1959.sp006308.
- [12] Diederik P. Kingma i Jimmy Ba. *Adam: A Method for Stochastic Optimization*. 2017. arXiv: 1412.6980 [cs.LG]. URL: <https://arxiv.org/abs/1412.6980>.
- [13] Alex Krizhevsky, Ilya Sutskever i Geoffrey E. Hinton. “ImageNet classification with deep convolutional neural networks”. W: *Commun. ACM* 60.6 (2017), s. 84–90. ISSN: 0001-0782. DOI: 10.1145/3065386. URL: <https://doi.org/10.1145/3065386>.
- [14] Y. LeCun. “Generalization and network design strategies”. W: (1989). URL: <https://yann.lecun.com/exdb/publis/pdf/lecun-89.pdf>.
- [15] Y. LeCun i in. “Backpropagation Applied to Handwritten Zip Code Recognition”. W: *Neural Computation* 1.4 (grud. 1989), s. 541–551. ISSN: 0899-7667. DOI: 10.1162/neco.1989.1.4.541. eprint: <https://direct.mit.edu/neco/article-pdf/1/4/541/811941/neco.1989.1.4.541.pdf>. URL: <https://doi.org/10.1162/neco.1989.1.4.541>.
- [16] Y. Lecun i in. “Gradient-based learning applied to document recognition”. W: *Proceedings of the IEEE* 86.11 (1998), s. 2278–2324. DOI: 10.1109/5.726791.
- [17] Yann LeCun i in. “Learning algorithms for classification: A comparison on handwritten digit recognition”. W: *Neural networks: the statistical mechanics perspective* 261.276 (1995), s. 2.
- [18] Seppo Linnainmaa. “TAYLOR EXPANSION OF THE ACCUMULATED ROUNDING ERROR”. W: *BIT Numerical Mathematics* 16 (1976), s. 146–160. DOI: <https://doi.org/10.1007%2Fb01931367>.
- [19] Joseph Redmon i in. “You only look once: Unified, real-time object detection”. W: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, s. 779–788.

- [20] Frank Rosenblatt. *The perceptron, a perceiving and recognizing automaton*. 1957. URL: <https://bpb-us-e2.wpmucdn.com/websites.umass.edu/dist/a/27637/files/2016/03/rosenblatt-1957.pdf>.
- [21] Frank Rosenblatt. “THE PERCEPTRON: A PROBABILISTIC MODEL FOR INFORMATION STORAGE AND ORGANIZATION IN THE BRAIN”. W: *Psychological Review* 65.6 (1958), s. 386–408. DOI: <https://doi.org/10.1037/h0042519>.
- [22] Jürgen Schmidhuber. *History of computer vision contests won by deep CNNs on GPU*. 2017. URL: <https://people.idsia.ch/~juergen/computer-vision-contests-won-by-gpu-cnns.html>.
- [23] Joseph Sobek i in. “MedYOLO: A Medical Image Object Detection Framework”. W: *Journal of Imaging Informatics in Medicine* (czer. 2024).
- [24] Yao Sun i in. “Large-scale building height retrieval from single SAR imagery based on bounding box regression networks”. W: *ISPRS Journal of Photogrammetry and Remote Sensing* 184 (2022), s. 79–95. ISSN: 0924-2716. DOI: <https://doi.org/10.1016/j.isprsjprs.2021.11.024>. URL: <https://www.sciencedirect.com/science/article/pii/S0924271621003221>.
- [25] Hector Calleros Szymon Nowakowski. “Applying Machine Learning to Research on Indigenous Peoples (2024)”. W: *In preparation* ().